

习题 1

1. 为保证形式化系统的有效性,下面哪个选项不是形式化系统需要具有的性质? ()
A. 完备性 B. 可靠性
C. 一致性 D. 可判定性
2. Deepmind研制的AlphaGo算法没有使用哪个人工智能方法? ()
A. 强化学习 B. 深度学习
C. 蒙特卡洛树搜索 D. 逻辑推理
3. 图灵奖获得者 Judea Pearl 将推理按照由易到难程度分成三个层次: ()。
A. 介入、关联、反事实 B. 关联、介入、反事实
C. 反事实、介入、关联 D. 关系、介入、反事实
4. 以下哪种搜索方法属于启发式搜索? ()
A. 广度优先搜索 B. 蒙特卡洛树搜索
C. 深度优先搜索 D. A*搜索
5. 以下哪一种算法不属于监督学习算法? ()
A. 隐马尔可夫链 B. 支持向量机
C. 聚类 D. 决策树
6. 以下哪种学习方法的学习目标是学习同一类数据的分布模式? ()
A. 监督学习 B. 无监督学习
C. 强化学习 D. 博弈对抗
7. 以机器为载体来模拟人类智能的某一方面,可通过以符号主义为核心的逻辑推理、以问题求解为核心的探寻搜索、以数据驱动为核心的机器学习、以行为主义为核心的强化学习、以博弈对抗为核心的决策智能等方法来实现。请比较上述人工智能不同方法的优劣。
8. 请参考图 1.1, 画出使用图灵机模型计算 $(5+2) \times 3$ 的过程示意图。
9. 推理方法在生活中无处不在,请你针对归纳推理、演绎推理和因果推理分别举出实际例子。
10. 监督学习和强化学习在做出预测后,都需要某种“反馈信息”来提升学习性能。请描述两种学习方法中利用“反馈信息”的不同。
11. 目前人工智能在大多数任务上所体现的性能与人类智能存在

不小差距。机器智能和人类智能之间进行相互协同所形成的人机混合增强是推动人工智能发展的务实之路。“假舆马者，非利足也，而致千里；假舟楫者，非能水也，而绝江河”，人类可以通过外界帮助来提升能力。请列举若干人机混合增强的例子。

习题4

1. 请判断下面说法是否正确：线性区别分析是在最大化类间方差和类内方差的比值（ ）。
A. 正确 B. 错误
2. 在决策树建立过程中，使用一个属性对某个结点对应的数据集进行划分后，结果具有高信息熵（high entropy），对于结果的描述，最贴切的是（ ）。
A. 纯度高 B. 纯度低
C. 有用 D. 无用
E. 以上描述都不贴切
3. 在一个监督学习任务中，每个数据样本有4个属性和一个类别标签，每种属性分别有3、2、2和2种可能的取值，类别标签有3种不同的取值。请问可能有多少种不同的样本？（注意，并不是在某个数据集中最多有多少种不同的样本，而是考虑所有可能的样本）（ ）。
A. 3 B. 6
C. 12 D. 24
E. 48 F. 72
4. 关于支持向量机，哪一种选择能正确填充下面的说法？（ ）
支持向量机是一种_____模型，其目标是_____分类间隔。
A. 生成，最大化 B. 生成，最小化
C. 判别，最大化 D. 判别，最小化
5. 以下哪种方法不属于监督学习方法？（ ）
A. 聚类 B. 决策树
C. 线性回归 D. 朴素贝叶斯
E. 支持向量机 F. 以上都不属于监督学习方法
6. 在Adaboosting的迭代中，从第 t 轮到第 $t+1$ 轮，某个被错误分类样本的惩罚增加了，可能因为该样本（ ）。
A. 被第 t 轮训练的弱分类器错误分类
B. 被第 t 轮后的集成分类器（强分类器）错误分类
C. 被到第 t 轮为止训练的大多数弱分类器错误分类
D. B和C都正确
E. A, B和C都正确
7. 假设有两批从同样的真实数据分布中采样得到去完成同一任务的数据集A和B。A包含100KB数据，B包含10KB数据。按照9:1这一同样比例随机将A和B分别划分为训练集和测试集。图4.13给出了数据集A和数据集B随着模型复杂度增加所对应的训练误差（A, Train以及B, Train）和测试误差（A, Test以及B, Test）曲线图。请指出哪个图正确表示了随着模型复杂度增加所对应训练误差和测试误差的变化曲线图。（ ）
8. 考虑一个在二维特征空间中的二分类问题。训练集包含8个样本，其在二维空间中的分布如图4.14所示。图4.14中不同




图4.13 数据集A和数据集B随模型复杂度增加所对应的训练误差和测试误差变化示意图




图4.14 两类分类问题中8个样本的分布图

类别的样本用不同的形状表示, 根据图4.14回答如下问题。

- (1) 使用实线画出使用SVM分类器可得到的分类边界, 并用圆圈标出支持向量。
 - (2) 在该分类边界下所得训练错误率为多少?
 - (3) 移除哪些样本可以让分类边界发生变化?
9. 加入L2标准化 (normalization) 后, 线性回归的损失函数的标准形式为:

$$L = (Y - Xw)^T (Y - Xw) + \lambda w^T w \quad \text{其中 } \lambda > 0$$

(1) 假设L2标准化项被误写为 $\lambda Y^T Y$, 请解释为什么该项起不到标准化的作用。

(2) 假设L2标准化项正确, 但 λ 小于0, 请解释为什么该项起不到标准化的作用。

10. 考虑下面一个数据集, 它记录了某学生多次考试的情况, 请根据提供的数据按要求构建决策树。

是否通过考试	是否认真复习	是否超常发挥
是	是	否
是	是	是
是	是	否
是	是	是
是	是	否
是	否	是
否	否	否
否	否	是

(1) 根据信息增益率选择第一个属性, 构建一个深度为1的决策树(根结点的深度为1)。

(2) 根据信息增益率构建完整的决策树。请回答, 这两个决策树的决策结果是否和训练数据一致, 并解释说明。

11. 考虑下面一个数据集:

序号	出去玩	天气状况	有同伴	零花钱	特殊节日	心情指数 (1差~5好)
1	是	好	无	多	是	5
2	是	一般	有	多	是	5
3	是	一般	有	少	否	1
4	是	一般	有	少	否	3
5	是	一般	有	少	否	5
6	是	好	无	多	是	5
7	是	好	无	多	是	5
8	否	一般	无	多	是	1
9	否	一般	有	少	否	1
10	否	一般	无	少	否	5

对于如上数据, 考虑使用Ada boosting方法来训练“是否出去玩”强分类器。每个弱分类器可考虑对单个属性的分类, 比如对于“心情指数”这一属性, 可考虑心情指数 >2 和心情指数 <4 两个方面。请回答下列问题。

- (1) Ada boosting在第一轮迭代中将会选择哪一个弱分类器?
- (2) 第一轮迭代前与迭代后每个样本的权重是多少?
- (3) 第二轮迭代选择的弱分类器是哪一个? 分类器权重是多少?
- (4) 写出三轮迭代后的强分类器的表达式 (每个弱分类器可用字母替代)

12. 线性判别分析模型由如下的假设所定义:

$$P(x|y=k) = \frac{e^{\frac{1}{2}(x-\mu_k)^T \Sigma^{-1}(x-\mu_k)}}{\sqrt{2\pi} |\Sigma|^{\frac{1}{2}}}$$

其决策边界由如下的对数几率比值确定:

$$\log \frac{P(y=1|x)}{P(y=0|x)} = \log \frac{P(x|y=1)P(y=1)}{P(x|y=0)P(y=0)}$$

请简要证明线性判别分析的决策边界是线性的。

习题6

1. 下面对误差反向传播 (error back propagation, BP) 描述不正确的是 ()。
 - A. BP算法是一种将输出层误差反向传播给隐藏层进行参数更新的方法
 - B. BP算法将误差从后向前传递, 获得各层单元所产生误差, 进而依据这个误差来让各层单元修正各单元参数
 - C. 对前馈神经网络而言, BP算法可调整相邻层神经元之间的连接权重大小
 - D. 在BP算法中, 每个神经元单元可包含不可偏导的映射函数
2. 以下关于梯度下降和随机梯度下降的说明, 哪一项是正确的? ()
 - i. 在梯度下降和随机梯度下降中, 为了最小化损失函数, 通常使用循环迭代的方式不断更新模型参数;
 - ii. 在每次迭代中, 随机梯度下降需要计算训练集所有样本的误差和, 用于更新模型参数;
 - iii. 在每次迭代中, 梯度下降使用所有数据或者部分训练数据, 用于更新模型参数。
 - A. i
 - B. ii
 - C. iii
 - D. i, ii
 - E. ii, iii
 - F. i, ii, iii
3. 关于sigmoid激活函数, 下列描述正确的是 ()。
 - A. 它是凸函数, 凸函数无法解决非凸问题

- B. 它可以有负值
- C. 它无法配合交叉熵损失函数使用
- D. 当输入值过大或者过小时, 梯度趋近于0, 容易造成梯度消失问题
4. 下面对前馈神经网络这种深度学习方法描述不正确的是 ()。
- A. 是一种端到端学习的方法
- B. 是一种监督学习的方法
- C. 实现了非线性映射
- D. 隐藏层数目大小对学习性能影响不大
5. 图6.21展示了长短时记忆网络的详细结构。如下描述正确的是 ()。
- A. 如果输入 x_t 为0向量, 则 $h_t = h_{t-1}$
- B. 如果 f_t 非常小或者为0, 则误差不会被反向传播到较早的时间节点
- C. f_t 、 i_t 和 o_t 的输出是非负数
- D. f_t 、 i_t 和 o_t 的输出可以被看作是概率分布, 其输出为非负数且和为1
6. 关于生成对抗网络的训练, 以下说法正确的是 ()。
- A. 为了加速生成对抗网络的训练, 通常采用交替训练一轮判别器和多轮生成器的方法
- B. 当生成器能够产生足以以假乱真的数据, 即 $D(G(z))$ 的输出稳定于接近1的值时, 训练就完成了
- C. 目标函数需要在训练初期提供足够的梯度, 使生成器更快开始产生能够混淆判别器的数据
- D. 生成对抗网络在经过足够长时间的训练后可以确保收敛到全局最优
7. 在训练生成对抗网络时, 发现损失函数的值很小, 但生成器产生的数据质量并不高这可能是因为 ()。
- A. 判别器欠拟合 B. 判别器过拟合
- C. 生成器欠拟合 D. 生成器过拟合
8. 请问深度学习和传统的机器学习有什么区别?
9. (1) 请说明单层感知机为何无法模拟逻辑异或操作?
- (2) 请设计一个前馈神经网络, 用于拟合异或函数。
10. 在前馈神经网络中, 所有的参数能否被初始化为0? 如果不能, 能否全部被初始化为其他的相同值? 为什么?
11. “编码器-解码器”框架被广泛用于机器翻译中, 其中编码器用于对源语言进行编码, 解码器用于产生目标语言。当编码器编码完毕后, 会将所得信息传给解码器, 同时给解码器“BOS”标签, 告知解码器可以开始解码。解码器依次产生目标语言词汇, 当产生“EOS”标签时解码结束。图6.35给出了通用机器翻译框架, 如果目标语言的词汇量大小为 V , y_t' 为模型预测的 V 维概率向量、 w_t 为所预测词语、 y_t 为真实值。
- (1) 写出解码器的损失函数。




图6.35 机器翻译中“编码-解码”框架

(2) 在模型过程中，通常会使用“微调”的方式更新预训练词向量。请写出 w_{a-1} 梯度。

12. 请证明为什么LSTM会解决循环神经网络（RNN）中所遇到的梯度消失问题。

RNN的计算公式可以写为：

$$c_t = W \cdot [x_t, c_{t-1}] + b$$

假设时序长度为 T ，则在梯度反向传播过程中， T 时刻的误差 l_T 对 W 的梯度为：

$$\frac{\partial l_T}{\partial W} = \sum_{i=1}^T \frac{\partial l_T}{\partial c_T} \cdot \left(\prod_{j=i+1}^T \frac{\partial c_j}{\partial c_{j-1}} \right) \cdot \frac{\partial c_T}{\partial W}$$


$\prod_{j=i+1}^T \frac{\partial c_j}{\partial c_{j-1}}$ 中每一项都是介于0和1之间的小数，当 T 很大时， $\prod_{j=i+1}^T \frac{\partial c_j}{\partial c_{j-1}}$ 值趋近于0，从而产生梯度消失问题。

在LSTM中， $c_t = f_t \cdot c_{t-1} + i_t \cdot \tanh(W_c \cdot [h_{t-1}, x_t] + b_c)$ ，因此 $\frac{\partial c_t}{\partial c_{t-1}} = f_t$ ，由于 f_t 通常为1或者为0，当为1时，所有梯度能够在LSTM中传递，当为0时，说明上一时刻的信息对当前时刻没有影响，因此没有必要传回梯度更新参数。这样，LSTM解决了RNN的梯度消失问题。

习题5

1. 可以从最小化每个类簇的方差这一视角来解释 K -均值聚类的结果,下面对这一视角描述不正确的是()。
 - A. 最终聚类结果中每个聚类集合中所包含数据呈现出来的差异性最小
 - B. 每个样本数据分别归属于与其距离最近的聚类质心所在聚类集合
 - C. 每个簇类的方差累加起来最小
 - D. 每个簇类的质心累加起来最小
2. 下面对相关性 (correlation) 和独立性 (independence) 描述不正确的是()。
 - A. 如果二维变量线性不相关,则皮尔逊相关系数等于0
 - B. 如果二维变量彼此独立,则皮尔逊相关系数等于0
 - C. “不相关”是一个比“独立”要强的概念,即不相关一定相互独立
 - D. 独立指两个变量彼此之间不相互影响
3. 下面对主成分分析的描述不正确的是()。
 - A. 主成分分析是一种特征降维方法
 - B. 主成分分析可保证原始高维样本数据被投影映射后,其方差保持最大
 - C. 在主成分分析中,将数据向方差最大方向进行投影,可使得数据蕴含信息没有丢失,以便在后续处理过程中“彰显个性”
 - D. 在主成分分析中,所得低维数据中每一维度之间具有极大相关度
4. 下面对特征人脸算法描述不正确的是()。
 - A. 特征人脸方法是一种应用主成分分析来实现人脸图像降维的方法
 - B. 特征人脸方法是用一种称为“特征人脸 (eigenface)”的特征向量按照线性组合形式来表达每一张原始人脸图像
 - C. 每一个特征人脸的维数与原始人脸图像的维数一样大
 - D. 特征人脸之间的相关度要尽可能大
5. 在潜在语义分析中,给定 M 个单词和 N 个文档所构成的单词-文档矩阵 (term-document) 矩阵,对其进行分解,将单词或文档映射到一个 R 维的隐性空间。下面描述不正确的是()。
 - A. 单词和文档映射到隐性空间后具有相同的维度
 - B. 通过矩阵分解可重建原始单词-文档矩阵,所得到的重建矩阵结果比原始单词-文档矩阵更好捕获了单词-单词、单词-文档、文档-文档之间的隐性关系
 - C. 这一映射过程中需要利用文档的类别信息
 - D. 隐性空间维度的大小由分解过程中所得对角矩阵中对角线上不为零的系数个数所决定
6. 图5.9给出了 K -均值聚类算法的初始状态和后续迭代结果。在图5.9左图给出的初始状态中,圆形代表被聚类数据点、

图5.9 K-均值聚类初始状态及
后续迭代聚类结果示意图



方形代表聚类质心。给出后续迭代中聚类质心在对应图中的结果。

- 说明在K-均值聚类算法执行的过程中, 其目标函数 $\sum_{i=1}^K \sum_{x \in G_i} \|x - c_i\|^2$ 是严格递减的, 并解释为什么K-均值聚类算法可以确保在有限步内收敛。
- 结合本章5.5.1小节的例子, 根据如下5轮(每轮投掷10次硬币)观测的结果, 使用EM算法分别估计硬币A和硬币B被投掷为正面的概率。

1	H	H	T	T	T	T	T	H	T	H
2	T	T	H	T	H	H	H	H	T	H
3	T	T	T	T	T	T	T	T	T	T
4	H	T	H	H	H	H	H	H	H	H
5	H	T	T	T	H	H	T	H	H	T

- EM算法和K-均值聚类算法有着非常相似的迭代结构, 可以说K-均值聚类算法是EM算法的一种特殊实现。如果将K-均值聚类中的聚类质心作为隐变量, 试从EM算法角度来解释K-均值聚类算法, 即描述K-均值聚类算法的E步骤和M步骤。
- 在机器学习中, 总体是特定研究任务中所定义的全部个体集合, 样本是从总体中选择出来的个体子集。一般使用从包含有限个体数目的样本中所得到的信息来作出描述总体的一般结论。样本方差 (sample variance) 和总体方差是两个不一样的概念。使用样本均值来估计总体均值是无偏的 (unbiased), 但使用样本方差 s^2 来估计总体方差 σ^2 却是有偏的 (biased)。总体方差 $\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2$, 其中 N 和 μ 分别是总体样本数量和总体均值。假设样本 x 包含了 n 个数据 $\{x_1, x_2, x_3, \dots, x_n\}$, 在了解下面样本均值是总体均值的无偏估

计以及 $E\left[\frac{1}{n}\sum_{i=1}^n(\bar{x}-x_i)^2\right]=\frac{n-1}{n}\sigma^2$ 的基础上, 证明如果样本方差定义为 $s^2=\frac{1}{n-1}\sum_{i=1}^n(x_i-\mu)^2$, 则 $E(s^2)=\sigma^2$ 。

a) 样本均值是对总体均值无偏估计的证明过程
证明:

$$\begin{aligned} E[\bar{x}] &= E\left[\frac{x_1+x_2+\cdots+x_n}{n}\right] \\ &= \frac{1}{n}E[x_1+x_2+\cdots+x_n] \\ &= \frac{1}{n}(E[x_1]+E[x_2]+\cdots+E[x_n]) \\ &= \frac{1}{n}(\mu+\mu+\cdots+\mu) \\ &= \frac{n\mu}{n} \\ &= \mu \end{aligned}$$

可见, 样本均值是对总体均值的无偏估计。

b) $E\left[\frac{1}{n}\sum_{i=1}^n(\bar{x}-x_i)^2\right]=\frac{n-1}{n}\sigma^2$

证明:

$$\begin{aligned} E\left[\frac{1}{n}\sum_{i=1}^n(\bar{x}-x_i)^2\right] &= E\left[\frac{1}{n}\sum_{i=1}^n((\bar{x}-\mu)-(x_i-\mu))^2\right] \\ &= E\left[\frac{1}{n}\sum_{i=1}^n((\bar{x}-\mu)^2-2(\bar{x}-\mu)(x_i-\mu)+(x_i-\mu)^2)\right] \\ &= E\left[(\bar{x}-\mu)^2-\frac{2(\bar{x}-\mu)}{n}\sum_{i=1}^n(x_i-\mu)+\frac{1}{n}\sum_{i=1}^n(x_i-\mu)^2\right] \\ &= E\left[(\bar{x}-\mu)^2-2(\bar{x}-\mu)^2+\frac{1}{n}\sum_{i=1}^n(x_i-\mu)^2\right] \\ &= E\left[\frac{1}{n}\sum_{i=1}^n(x_i-\mu)^2\right]-E[(\bar{x}-\mu)^2] \\ &= \sigma^2-\frac{\sigma^2}{n} \\ &= \frac{n-1}{n}\sigma^2 \end{aligned}$$

在上面的证明过程中, 利用了如下的结果:

由于 $E(X^2)=[E(X)]^2+Var(X)$ 、 $Var(a+X)=Var(X)$ 、 $Var(aX)=a^2Var(X)$

因此

$$\begin{aligned} E[(\bar{x}-\mu)^2] &= [E(\bar{x}-\mu)]^2+Var(\bar{x}-\mu)=Var(\bar{x})=Var\left(\frac{x_1+x_2+\cdots+x_n}{n}\right) \\ &= \frac{n\sigma^2}{n^2}=\frac{\sigma^2}{n} \end{aligned}$$

从 $E\left[\frac{1}{n}\sum_{i=1}^n(\bar{x}-x_i)^2\right]=\frac{n-1}{n}\sigma^2$ 可知, $\frac{1}{n}\sum_{i=1}^n(\bar{x}-x_i)^2$ 是对总体方差的一个低估, 因此在用样本方差来代替总体方差时, 需要将样本方差定义为 $\frac{1}{n-1}\sum_{i=1}^n(x_i-\mu)^2$, 这才能从样本方差出发, 得到总体方差 σ^2 , 这是一个无偏估计。


7.5 小结

本章介绍了基于价值的强化学习算法和基于策略的强化学习算法，这些算法都可以认为是基于通用策略迭代的框架的方法，即算法是由策略评估和策略优化两个步骤组成的。

图7.20概括了本章中介绍的强化学习算法。图中从两个角度对强化学习算法做了分类，其中依靠对环境（即马尔可夫随机过程）的先验知识或建模的算法称为基于模型（model-based）的方法，反之称为无模型的方法（model-free）；只对价值函数建模并利用策略优化定理求解的方法称为基于价值（value-based）的方法，对策略函数建模并利用策略梯度定理求解的方法称为基于策略（policy-based）的方法。

“欲粟者务时，欲治者因势”。强化学习作为一种通用的策略学习框架，向人们展示了其强大的能力和应用前景。虽然强化学习尚不成熟，导致它在很多问题上并不容易应用，但是对强化学习的研究，必将推动人工智能的发展并带来更加广泛的应用。

图7.20 本章所介绍方法之间相互关系示意图



习题7

- 下面对强化学习、监督学习和深度卷积神经网络学习的描述正确的是()。
 - 评估学习方式、有标注信息学习方式、端到端学习方式
 - 有标注信息学习方式、端到端学习方式、端到端学习方式
 - 评估学习方式、端到端学习方式、端到端学习方式
 - 无标注学习、有标注信息学习方式、端到端学习方式
- 在强化学习中,通过哪两个步骤的迭代,来学习得到最佳策略?()
 - 价值函数计算与动作-价值函数计算
 - 动态规划与Q-Learning
 - 贪心策略优化与Q-learning
 - 策略优化与策略评估
- 在强化学习中,哪个机制的引入使得强化学习具备了在利用与探索中寻求平衡的能力?()
 - ϵ 贪心策略
 - 蒙特卡洛采样
 - 动态规划
 - 贝尔曼方程
- 与马尔可夫奖励过程相比,马尔可夫决策过程引入了哪一个新的元素?()
 - 反馈
 - 动作
 - 终止状态
 - 概率转移矩阵
- 在本章内容范围内,“在状态 s ,按照某个策略行动后在未来所获得回报值的期望”,这句话描述了状态 s 的();“在状态 s ,按照某个策略采取动作 a 后在未来所获得回报值的期望”,这句话描述了状态 s 的()。
 - 策略优化
 - 价值函数
 - 动作-价值函数
 - 采样函数
- 将图7.2中的机器人寻路问题简化为图7.21的 2×2 的网格,假设有位于 s_1 位置的机器人拟从 s_1 这一初始位置向 s_4 这一目标位置移动。机器人每次只能向上或者向右移动一个方格,到达目标位置 s_4 则会获得奖励且游戏终止,机器人在移动过程中如果越出方格(s_d)则会被惩罚且被损坏,并且游戏终止。奖励值定义如下:当 $S_{t+1}=s_4$ 时奖励值为1,当 $S_{t+1}=s_d$ 时惩罚值为-1,其他情况下奖励值为0。若折扣因子 $\gamma=0.99$,智能体在 s_1 、 s_2 、 s_3 的策略都初始化为上,终止状态 s_4 、 s_d 的价值函数定义为0,试通过联立贝尔曼方程给出状态 s_1 、 s_2 、 s_3 的价值函数。
- 在第6题中,若每个状态的价值函数都初始化为0,智能体在 s_1 、 s_2 、 s_3 的策略都初始化为上,试优化智能体在状态 s_3 的策略。(提示:使用策略优化定理)
- 在第6题中,若每个状态的价值函数都初始化为0,智能体在

图7.21 2×2 的机器人寻路问题

S_3	S_4
S_1	S_2

图7.22 Q学习算法的初始状态

0.1/0	0/0
0.1/0	0.1/0

9. 在第6题中, 若图7.22表示算法的初始状态, 其中 a/b 表示对应状态的动作-价值函数的取值, 斜线左侧的 a 表示 $q_{\pi}(s, \text{上})$, 斜线右侧的 b 表示 $q_{\pi}(s, \text{右})$ 。若 $\alpha = 0.5$, 试给出算法7.6中的Q学习算法的一个片段的执行过程, 并给出执行完该片段后每个状态的策略。

10. 采样时策略和更新时策略彼此不同的算法称为离策略算法。反之, 采样时策略和更新时策略相同的算法称为在策略算法。算法7.7给出的Q学习是一个离策略算法, 请给出其对应的在策略版本——Sarsa算法。
11. 回顾将价值函数作为Actor-Critic算法的基准函数的推导过程, 若将基准函数设置为 $h(s, a)$, 指出推导过程中的哪一步不再适用。

参考文献

- [1] ANDREAE J H. Learning Machines: A Unified View [J]. Standard Telecommunications Laboratories, 1966.
- [2] BARTOA G, SUTTON R S, ANDERSON W. Neuronlike adaptive elements that can solve difficult learning control problems [J]. IEEE transactions on systems, man, and cybernetics, 5: 834-846, 1983.
- [3] BARTO A G, DUFF M. Monte Carlo matrix inversion and reinforcement learning [J]. Advances in Neural Information Processing Systems, 1994.
- [4] BELLMAN R. A Markovian decision process [J]. Journal of Mathematics and Mechanics, 6(5): 679-684, 1957.
- [5] BELLMAN R. Dynamic programming [J]. Courier Corporation, 2013.
- [6] BENGIO Y, et al. Curriculum learning [C] //Proceedings of the 26th annual international conference on machine learning. Cambridge, MA: ACM press, 2009.
- [7] BERTSEKAS D P, TSITSIKLIS J N. Parallel and distributed computation: numerical methods [M]. Englewood Cliffs, NJ: Prentice hall, 1989.
- [8] DAYAN P. The convergence of TD (λ) for general λ [J]. Machine learning, 8(3-4): 341-362, 1992.
- [9] ECOFFET A, et al. Go-Explore: a New Approach for Hard-Exploration Problems [J]. arXiv preprint arXiv: 1901.10995, 2019.
- [10] HENDERSON P, et al. Deep reinforcement learning that matters [J]. Thirty-Second AAAI Conference on Artificial Intelligence, 2018.
- [11] HESSEL M, et al. Rainbow: Combining improvements in deep reinforcement learning [J]. Thirty-Second AAAI Conference on Artificial Intelligence, 2018.
- [12] KALOS M H, WHITLOCK P A. Monte carlo methods [M]. New Jersey: John Wiley & Sons, 2009.

